



DSO代码解读

龚益群
2019年09月20日

2019.10.10

数据结构[6]:

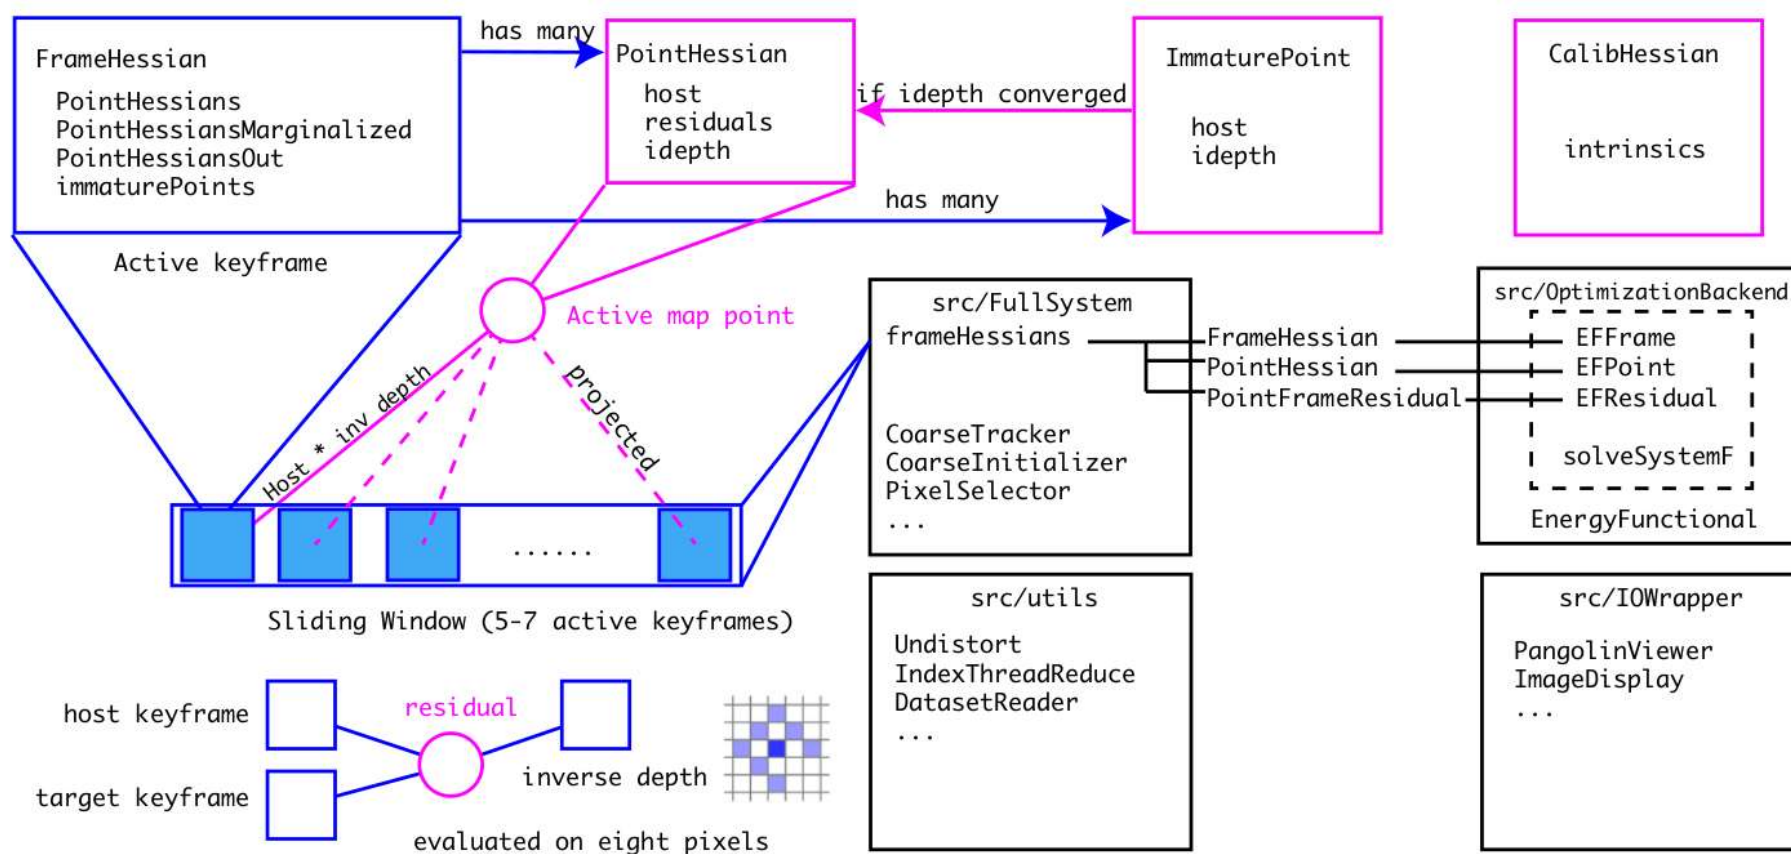
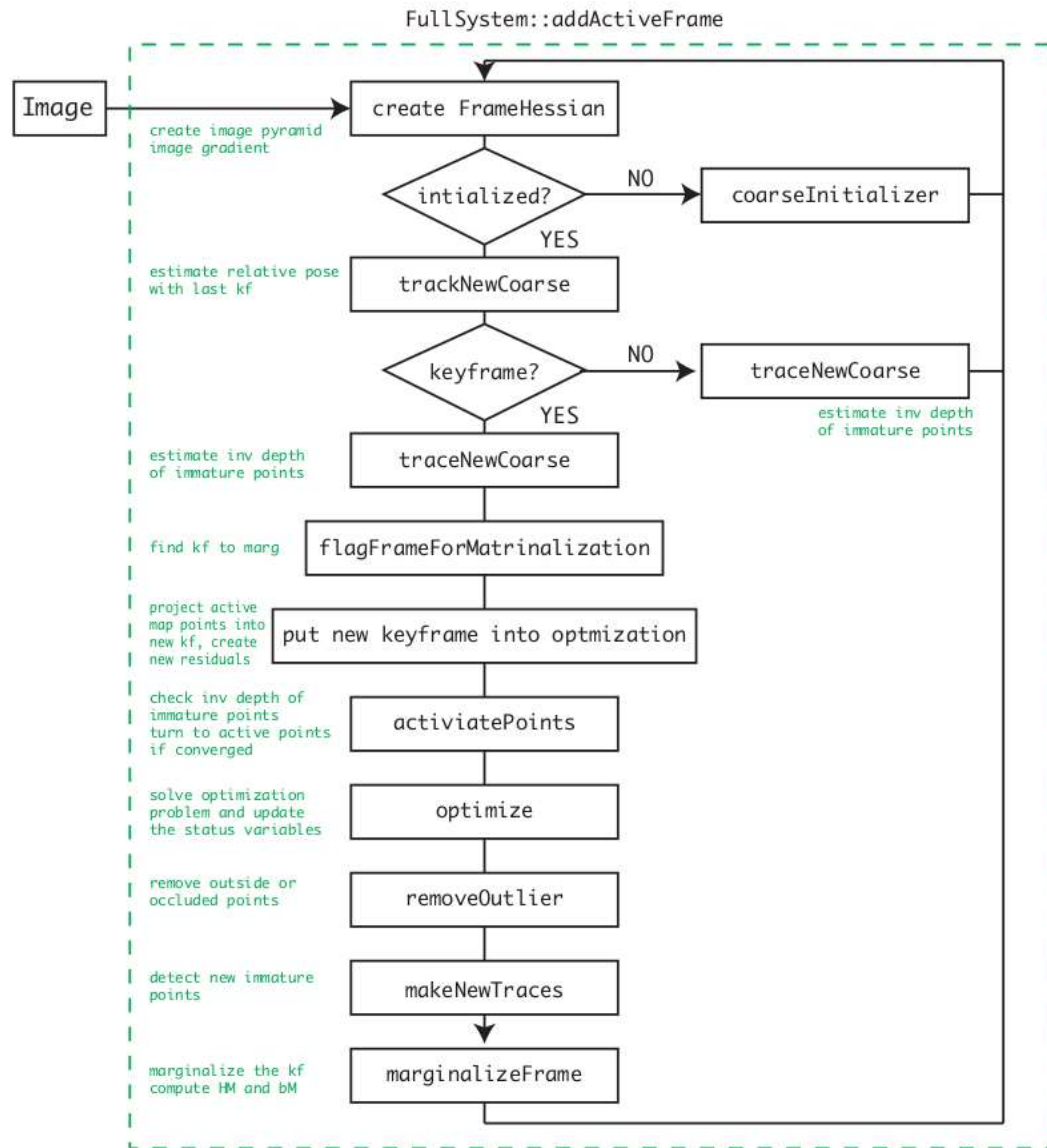


Figure 1: Framework of DSO.

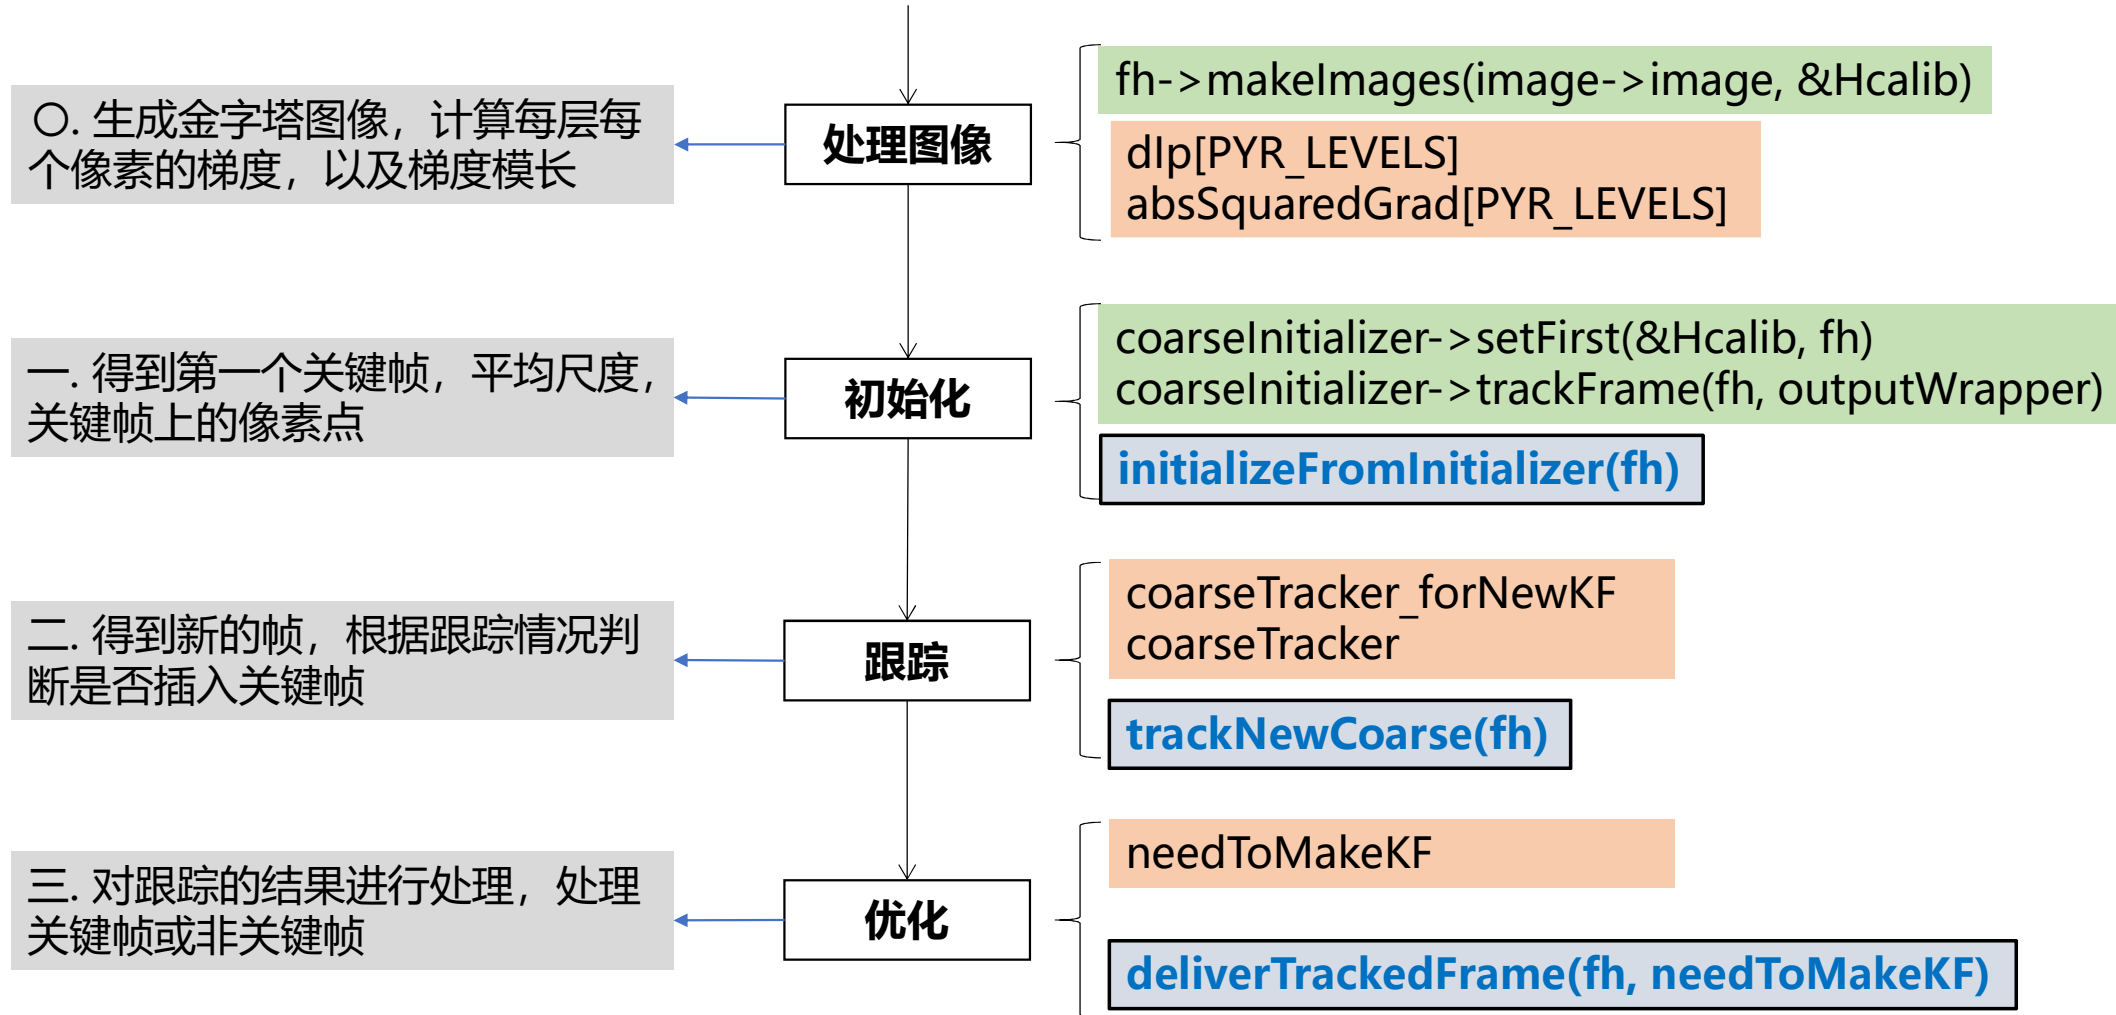
算法流程^[6]:



2019.10.10

Figure 2: Pipeline of the frontend.

addActiveFrame:

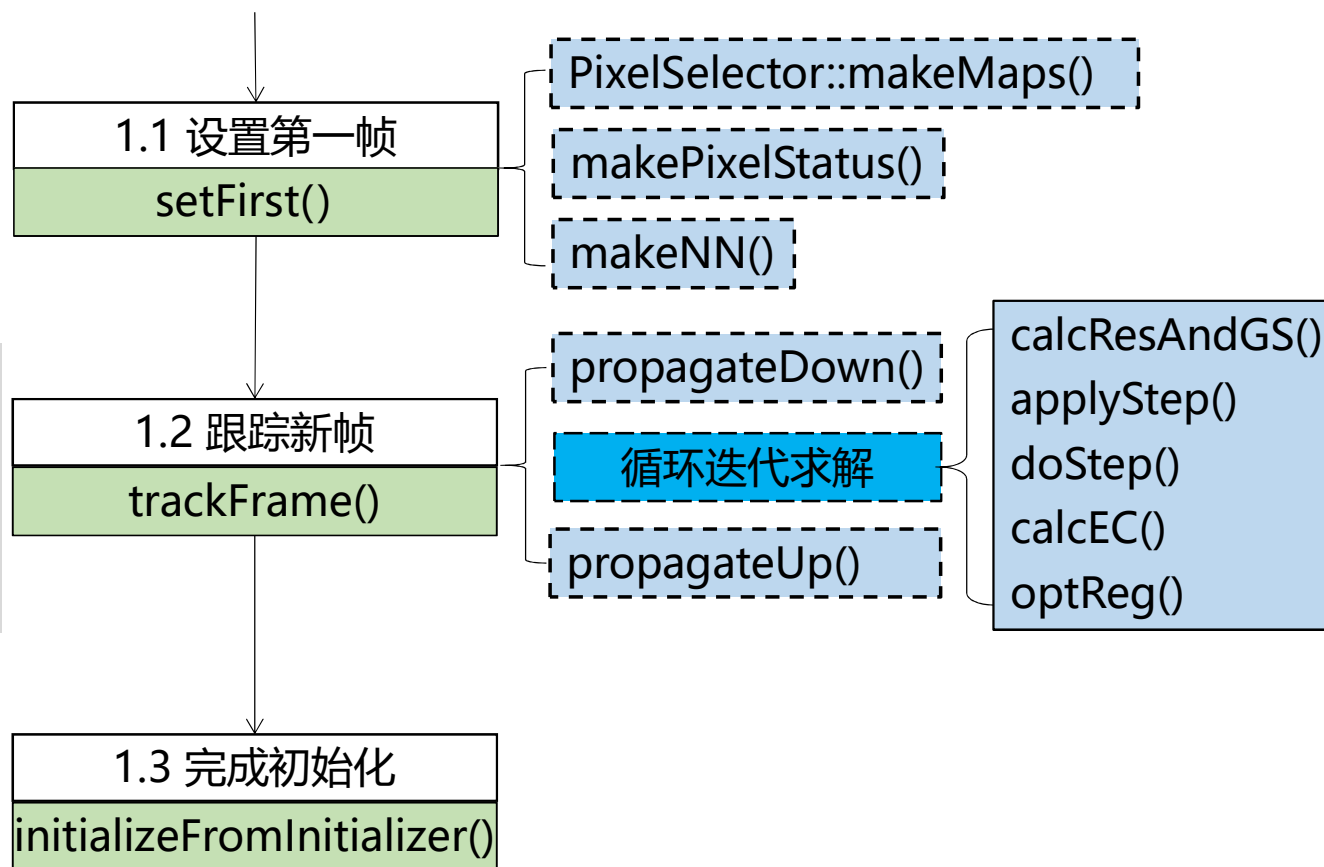


一、初始化:

- 提取第0层的特征, 取网格内随机方向梯度最大点
- 提取1-5层的特征, 取网格内具有dx/dy最大梯度点
- new用于初始化的点, 得到每个点同层最近的10个点(neighbours), 和上一层最近的点(parent)

- 当检测到位移足够大时, 开始从金字塔顶层向底层使用LM优化位姿, 光度参数, 逆深度。
- 然后将逆深度由**底层向顶层传播逆深度**, 用于下次优化做初值。
- 优化到满足位移的后5帧, 位移小或中间的帧删除fh。

- 将第一帧插入关键帧, 插入能量方程中 (后面也会把这个最新帧插入关键帧)
- 使用**第0层**点的均值作为归一尺度
- 把**第0层**点创建为PointHessian, 并插入能量方程insertPoint() (有先验)
- 设置第一帧和最新帧的FrameShell信息, 作为待估计量



CoarseInitializer.cpp:

Jacobian

初始化中的能量方程

$$\begin{aligned} E_{\mathbf{p}_j} &= \sum_{\mathbf{p}_i \in \mathcal{N}_p} w_p \left\| \left(I_j [\mathbf{p}_j] - b_j \right) - \frac{t_j e^{a_j}}{t_i e^{a_i}} (I_i [\mathbf{p}_i] - b_i) \right\|_r \\ &= \sum_{\mathbf{p}_i \in \mathcal{N}_p} w_p \left\| I_j [\mathbf{p}_j] - \frac{t_j e^{a_j}}{t_i e^{a_i}} I_i [\mathbf{p}_i] - \left(b_j - \frac{t_j e^{a_j}}{t_i e^{a_i}} b_i \right) \right\|_r \end{aligned} \quad (1)$$

$$\mathbf{p}_j = \Pi_c \left(\mathbf{R} \Pi_c^{-1} (\mathbf{p}_i, d_{\mathbf{p}_i}) + \mathbf{t} \right) \quad \text{with} \quad \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ 0 & 1 \end{bmatrix} := \mathbf{T}_j \mathbf{T}_i^{-1} \quad (2)$$

按照代码中:

$$\begin{aligned} \mathbf{P}'_i &= \pi_c^{-1} (\mathbf{p}_i) = \mathbf{K}^{-1} \begin{pmatrix} \mathbf{p}_i \\ 1 \end{pmatrix} \\ \mathbf{P}'_j &= \mathbf{R} \mathbf{P}'_i + \mathbf{t} d_{\mathbf{p}_i} \\ \begin{pmatrix} \mathbf{p}_j \\ 1 \end{pmatrix} &= \pi_c (\omega (\mathbf{P}'_j)) \end{aligned} \quad (3)$$

初始化中的光度参数求导

光度求导

初始化对目标帧进行求导

$$\begin{aligned} \mathbf{J}_{\text{photo}} &= \frac{\partial r_k}{\partial \delta_{\text{photo}}} \\ &= \begin{pmatrix} \frac{\partial r_k}{\partial \delta a_j} & \frac{\partial r_k}{\partial \delta b_j} \end{pmatrix} \\ &= \begin{pmatrix} -\frac{t_j e^{a_j}}{t_i e^{a_i}} (I_i [\mathbf{p}_i] - b_i) & -1 \end{pmatrix} \end{aligned} \quad (4)$$

CoarseInitializer.cpp:

位姿求导

初始化中的位姿求导

$$\mathbf{J}_I = \frac{\partial I_j}{\partial \mathbf{p}_j} = \left(\frac{\partial I_j}{\partial \mathbf{p}'_x} \frac{\partial I_j}{\partial \mathbf{p}'_y} \right) = (d_x \ d_y) \quad (5)$$

对目标帧位姿求导有

$$\begin{aligned} \frac{\partial r_k}{\partial \delta \xi} &= \mathbf{J}_I \cdot \frac{\partial \mathbf{p}_j}{\partial \mathbf{P}'_j} \cdot \frac{\partial \mathbf{P}'_j}{\partial \delta \xi} \\ &= (d_x \ f_x \ d_y \ f_y) \begin{pmatrix} \frac{1}{P'_z} & 0 & -\frac{P'_x}{P'^2_z} \\ 0 & \frac{1}{P'_z} & -\frac{P'_y}{P'^2_z} \end{pmatrix} d_{\mathbf{p}_i} \left(\mathbf{I} - \frac{1}{d_{\mathbf{p}_i}} [\mathbf{P}'_j]_x \right) \\ &= (d_x \ f_x \ d_y \ f_y) \begin{pmatrix} \frac{1}{P'_z} & 0 & -\frac{P'_x}{P'^2_z} \\ 0 & \frac{1}{P'_z} & -\frac{P'_y}{P'^2_z} \end{pmatrix} \begin{pmatrix} d_{\mathbf{p}_i} & 0 & 0 & 0 & P'_z & -P'_y \\ 0 & d_{\mathbf{p}_i} & 0 & -P'_z & 0 & P'_x \\ 0 & 0 & d_{\mathbf{p}_i} & P'_y & -P'_x & 0 \end{pmatrix} \\ &= (d_x \ f_x \ d_y \ f_y) \begin{pmatrix} \frac{d_{\mathbf{p}_i}}{P'_z} & 0 & -\frac{d_{\mathbf{p}_i} P'_x}{P'_z} & -\frac{P'_x P'_y}{P'_z} & 1 + \frac{P'^2_x}{P'^2_z} & -\frac{P'_y}{P'_z} \\ 0 & \frac{d_{\mathbf{p}_i}}{P'_z} & -\frac{d_{\mathbf{p}_i} P'_y}{P'_z} & -1 - \frac{P'^2_y}{P'^2_z} & \frac{P'_x P'_y}{P'^2_z} & \frac{P'_x}{P'_z} \end{pmatrix} \end{aligned} \quad (6)$$

初始化中的逆深度求导

逆深度求导

$$\begin{aligned} \frac{\partial r_k}{\partial \delta d_{\mathbf{p}_i}} &= \mathbf{J}_I \cdot \frac{\partial \mathbf{p}_j}{\partial \mathbf{P}'_j} \cdot \frac{\partial \mathbf{P}'_j}{\partial \delta d_{\mathbf{p}_i}} \\ &= (d_x \ d_y) \begin{pmatrix} f_x & 0 \\ 0 & f_y \end{pmatrix} \begin{pmatrix} \frac{1}{P'_z} & 0 & -\frac{P'_x}{P'^2_z} \\ 0 & \frac{1}{P'_z} & -\frac{P'_y}{P'^2_z} \end{pmatrix} \begin{pmatrix} t_x \\ t_y \\ t_z \end{pmatrix} \\ &= (d_x \ f_x \ d_y \ f_y) \frac{1}{P'_z} \begin{pmatrix} t_x - \frac{P'_x}{P'_z} t_z \\ t_y - \frac{P'_y}{P'_z} t_z \end{pmatrix} \\ &= \frac{1}{P'_z} d_x f_x \left(t_x - \frac{P'_x}{P'_z} t_z \right) + \frac{1}{P'_z} d_y f_y \left(t_y - \frac{P'_y}{P'_z} t_z \right) \end{aligned} \quad (7)$$

CoarseInitializer.cpp:

DSO中正规方程维护

- DSO中维护的是把逆深度部分舒尔消元之后的矩阵，因此分别计算H/b, HSC/bSC.

U ₁						
	U ₂			W		
		U ₃				
			V ₁			
				V ₂		
	W ^T				V ₃	
						V ₄

$$H = J^T \Sigma^{-1} J = \left[\begin{array}{c|c} A^T \Sigma^{-1} A & A^T \Sigma^{-1} B \\ \hline B^T \Sigma^{-1} A & B^T \Sigma^{-1} B \end{array} \right] = \left[\begin{array}{cc} U & W \\ W^T & V \end{array} \right]$$

这样公式可以表示为

$$\begin{bmatrix} U & W \\ W^T & V \end{bmatrix} \begin{bmatrix} \Delta x_c \\ \Delta x_p \end{bmatrix} = \begin{bmatrix} b_A \\ b_B \end{bmatrix} \quad (8)$$

计算V的舒尔补进行分块消元:

$$(U - WV^{-1}W^T)\Delta x_c = b_A - WV^{-1}b_B \quad (9)$$

通过 (9) 式解出 Δx_c 代入公式 (10) 可以解出 Δx_p

$$V\Delta x_p = b_B - W^T\Delta x_c \quad (10)$$

公式 (8) 变为:

$$\begin{bmatrix} U - WV^{-1}W^T & 0 \\ W^T & V \end{bmatrix} \begin{bmatrix} \Delta x_c \\ \Delta x_p \end{bmatrix} = \begin{bmatrix} b_A - WV^{-1}b_B \\ b_B \end{bmatrix} \quad (11)$$

PixelSelector2.cpp:

PixelSelector::makeMaps()

- **makeHists(fh)**计算直方图, 以及选点的阈值
- **select()**当前帧上选择符合条件的像素, densities[] = {0.03,0.05,0.15,0.5,1}
- 计算当前得到的点和需要的点数目比, 据此来**动态调节**网格大小


```
// 相当于覆盖的面积, 每一个像素对应一个pot*pot  
K = numHave * (currentPotential+1) * (currentPotential+1);  
// 除以目标点数, 得到应该设置的pot大小  
idealPotential = sqrtf(K/numWant)-1;
```

- 比例超过或小于0.25就会递归重新计算
- 如果点还是多, 就随机删除一些点

PixelSelector2.cpp:

PixelSelector::makeHists()

- 每个格32*32大小
- 在格内创建直方图**hist0**
- 统计直方图中的像素点占50%位置的梯度作为**阈值ths**
- 对阈值进行3*3的**均值滤波thsSmoothed**



hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed
hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed
hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed
hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed	hist0 ths thsSmoothed



PixelSelector2.cpp:

PixelSelector::select()

对于第0层的金字塔图像

- 遍历每一个像素，取大于所求阈值，且在pot内最大的
- 红pot对应4个像素，绿pot对应4个红pot，蓝pot对应4个绿pot
- 红色的使用金字塔0层上的梯度，阈值为thsSmoothed
- 绿色的使用金字塔1层上的梯度，阈值为红色的0.75倍
- 蓝色的使用金字塔2层上的梯度，阈值为绿色的0.75倍
- 比较大小都使用零层随机方向上的梯度
- 优先级红 > 绿 > 蓝，优先级高的找到了就不在低的里面找

4*pot



PixelSelector.h:

```
makePixelStatus()
```

```
template<int pot> inline int gridMaxSelection()
```

对于1-5层的金字塔图像

- 同样动态调节pot的大小，来保证提取合适的数目
- 每个pot内梯度大于阈值，且 $\text{gradx} / \text{grady} / \text{gradx}-\text{grady} / \text{gradx}+\text{grady}$ 中有最大值的则被选中

4*pot

#							

CoarseInitializer.cpp:

calcResAndGS()

DSO在初始化时为了使得
尺度收敛增加两个能量项

当位移不够大(snapped=false):

$$E_{pj} := E_{pj} + \alpha_w [(d_{p_i} - 1)^2 + \|t\|_2 \cdot N] \quad (12)$$

因此有代码:

```
1 JbBuffer_new[i][8] += alphaOpt*(point->idepth_new - 1); // r*dd
2 JbBuffer_new[i][9] += alphaOpt; // 对逆深度导数为1 // dd*dd
3
4 // t*t*npts
5 // 给 t 对应的Hessian, 对角线加上一个数, b也加上
6 H_out(0,0) += alphaOpt*npts;
7 H_out(1,1) += alphaOpt*npts;
8 H_out(2,2) += alphaOpt*npts;
9
10 // 李代数, 平移部分 (上一次的位姿值)
11 Vec3f tlog = refToNew.log().head<3>().cast<float>();
12 b_out[0] += tlog[0]*alphaOpt*npts;
13 b_out[1] += tlog[1]*alphaOpt*npts;
14 b_out[2] += tlog[2]*alphaOpt*npts;
```

当位移足够大(snapped=true)时:

$$E_{pj} := E_{pj} + (d_{p_i} - d_{iR})^2 \quad (13)$$

因此有代码:

```
1 JbBuffer_new[i][8] += couplingWeight*(point->idepth_new - point->iR);
2 JbBuffer_new[i][9] += couplingWeight;
```


CoarseInitializer.cpp:

propagateDown()

propagateUp()

逆深度在不同层之间传递使用parent点来作为关联，融合策略采用高斯归一化积

$$\Sigma^{-1} = \sum_{k=1}^K \Sigma_k^{-1},$$
$$\Sigma^{-1} \mu = \sum_{k=1}^N \Sigma_k^{-1} \mu_k,$$



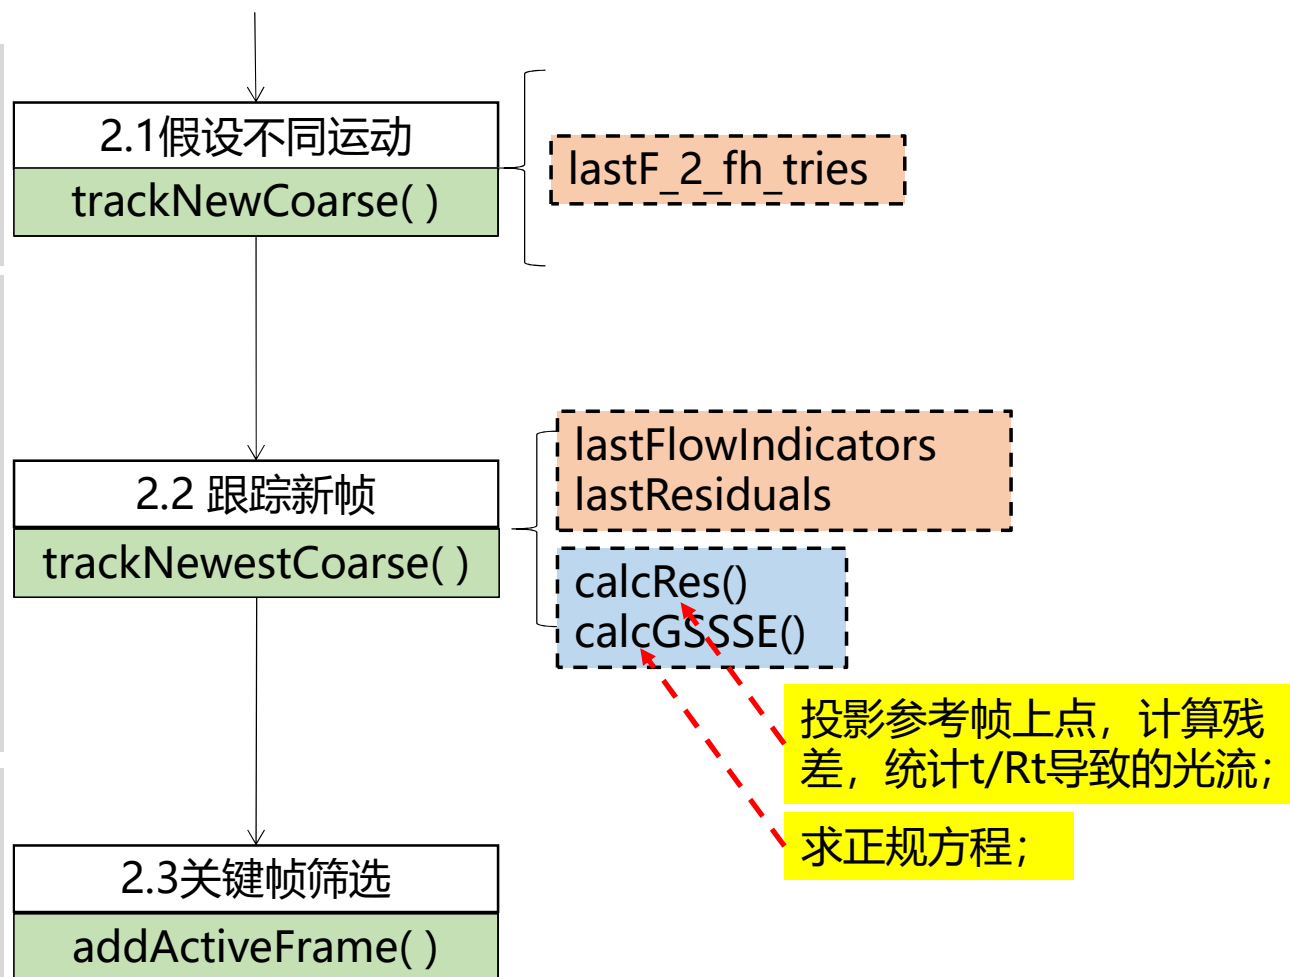
$$\frac{1}{\sigma^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}$$
$$\frac{\mu}{\sigma^2} = \frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}$$

optReg()

函数使用同金字塔层之间的neighbours点的中位值对iR进行平滑处理

二、跟踪：

- 分别假设**5种**：匀速、半速、倍速、零速、以及从参考帧就没动。
- 另假设匀速基础上有**26种**旋转运动。例：Quaterniond(1,rotDelta,0,0)
- 由粗到精迭代优化，如果大于能量阈值的点超过60%，则**放大阈值**，且该层**多优化一遍**。
- 如果**某一层**的能量值大于1.5倍最小值，直接判断为失败，结束节省时间。
- 如果跟踪成功且**第0层**好于当前，则保留结果，并更新每一层的最小能量值。
- **第0层**最小值小于阈值则停止，把目前最好的值作为**下次跟踪的阈值**。
- 可以设置定时插入
- 通过**像素移动**的大小判断，位移较大、平移+旋转较大、曝光变化大、跟踪得到的能量变化大，则插入（论文中说只考虑位移，有效处理遮挡/去遮挡）



【问题】：如何理解这个判断关键帧策略有效处理遮挡？

CoarseTracker.cpp:

- 没用pattern，只使用投影过来的中心点像素误差
- 优化的变量只有相机位姿和光度参数，没有逆深度
- 其中用到Huber函数

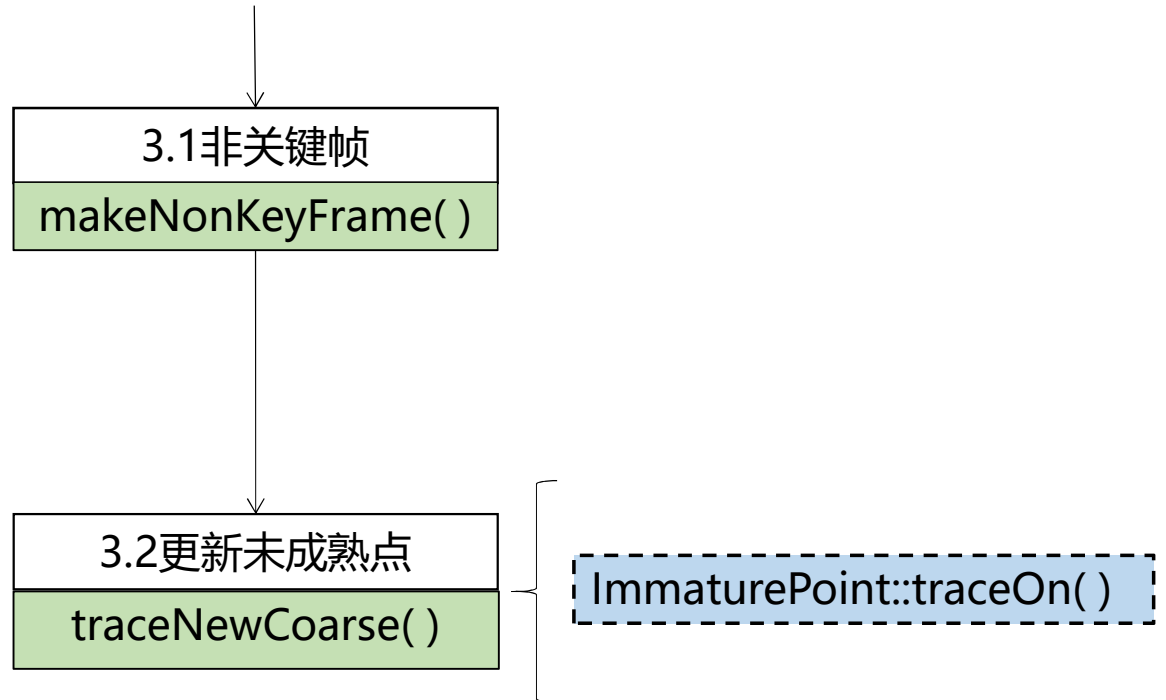
$$\rho_H(e) = \begin{cases} \frac{1}{2}e^2 & \text{for } |e| \leq k \\ k|e| - \frac{1}{2}k^2 & \text{for } |e| > k \end{cases}$$

$$w_H(e) = \begin{cases} 1 & \text{for } |e| \leq k \\ k/|e| & \text{for } |e| > k \end{cases}$$

$$w_H(e) \times (2 - w_H(e)) \times e^2 = 2 \times \rho_H(e)$$

三、优化:


- 更新未成熟点ImmaturePoint的逆深度范围后，删除fh，只保留FrameShell。
- 根据逆深度范围得到极线搜索的范围
- 计算图像梯度和极线夹角的大小，如果太大则误差会很大
- 在极线上按照一定步长进行搜索能量最小的位置，和大于设置半径(2)的第二小的位置，后/前作为质量，越大越好
- 沿着极线进行GN优化，直到增量足够小
- 根据搜索得到的投影位置计算新的逆深度范围



ImmaturePoint.cpp:

traceOn()

公式 (14) 可知极线方向和
梯度方向**夹角过大**误差会变大



$$l_0 + \lambda^* \begin{pmatrix} l_x \\ l_y \end{pmatrix} \stackrel{!}{=} g_0 + \gamma \begin{pmatrix} -g_y \\ g_x \end{pmatrix}, \quad \gamma \in \mathbb{R} \quad (14)$$

$$\begin{aligned} \begin{bmatrix} u' \\ v' \\ 1 \end{bmatrix} &= \Pi_c \left(KR \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} + Kt \cdot d_p \right) \\ &= \Pi_c \left(\begin{bmatrix} pr_x \\ pr_y \\ pr_z \end{bmatrix} + d_p \cdot \begin{bmatrix} kt_x \\ kt_y \\ kt_z \end{bmatrix} \right) \end{aligned} \quad (15)$$

$$\begin{aligned} u' &= \frac{pr_x + d_p \cdot kt_x}{pr_z + d_p \cdot kt_z} \\ v' &= \frac{pr_y + d_p \cdot kt_y}{pr_z + d_p \cdot kt_z} \end{aligned} \quad (16)$$

$$\begin{aligned} \Rightarrow d_p &= \frac{u' \cdot pr_z - pr_x}{kt_x - u' \cdot kt_z} \\ d_p &= \frac{v' \cdot pr_z - pr_y}{kt_y - v' \cdot kt_z} \end{aligned}$$

已知匹配点计算**逆深度范围**
(会在公式 (16) 点上再加
误差)

2019.10.10

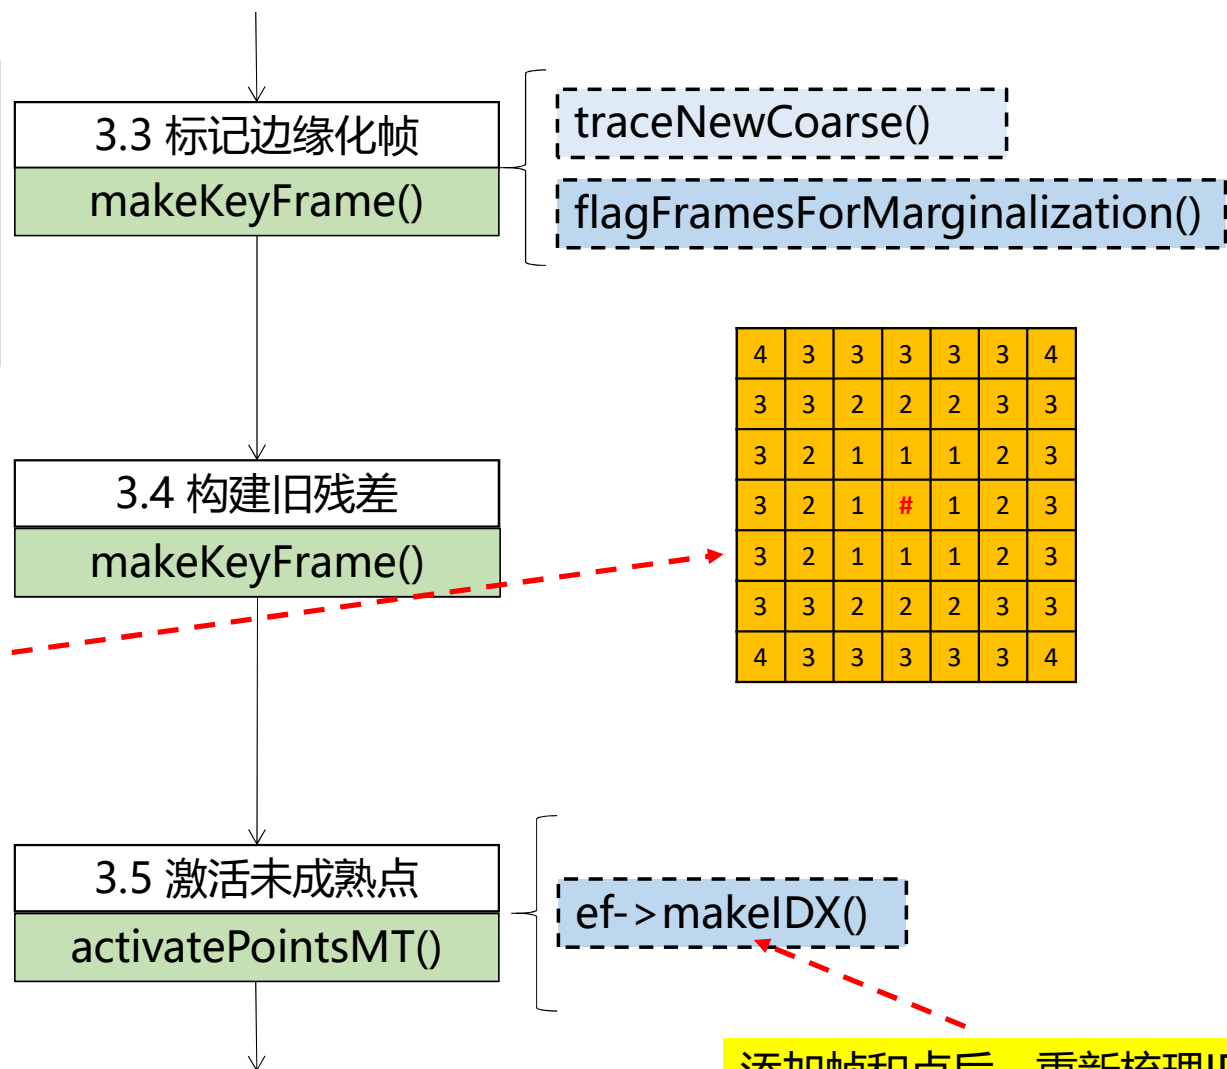
【问题】：坐标加0.5的作用？

三、优化:

- 留下的点(去除边缘化+删除)占所有点小于5%
- 和参考帧比**曝光变化**较大
- 保证滑窗内有5个关键帧
- 如果还大于7个关键帧, 则边缘化掉到最新关键帧的距离占所有距离比最大的。保证良好的空间结构

- 加入关键帧, 能量函数中insertFrame(), 设置相对位姿和线性化点
- 构建新关键帧和之前关键帧之间的残差PointFrameResidual, 并插入能量函数insertResidual(), DSO选择先**全部构建**, 之后再删除

- 在最新关键帧上生成**距离地图**(点附近第一层是1, 第二层2,.....)
- 满足搜索范围小于8, 质量好, 逆深度为正, 删除外点和边缘化帧上的点
- 将点投影到**距离地图**上, 大于阈值(阈值根据当前点数量调节)激活
- 使用LM优化选出来点的**逆深度**, 将内点构建PointHessian和残差一起加入能量函数
- 删除未收敛的点

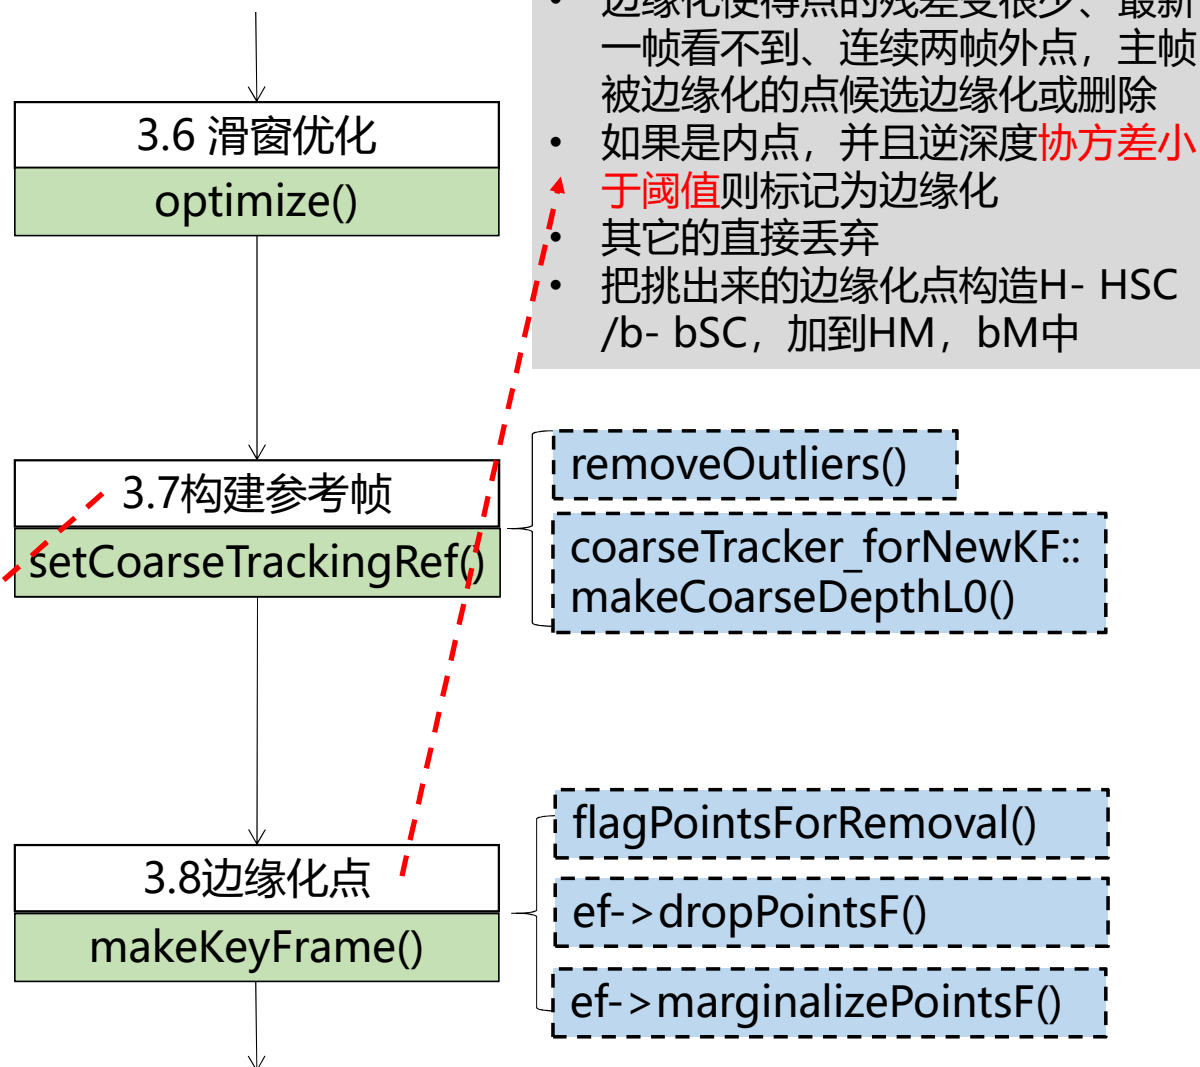


添加帧和点后, 重新梳理ID

三、优化:

- 使用GN法对位姿、光度参数、逆深度、相机内参进行优化, 由于边缘化需要维护两个H矩阵和b向量
- 其中位姿和相机内参使用FEJ, 除了最新一帧, 相关H矩阵固定在上一次优化, 残差仍然使用更新后的状态求
- 被边缘化部分残差更新: $b = b - H * \delta$
- 其中第一帧位姿和其上点逆深度, 由于初始化具有先验, 光度参数有先验
- 使用伴随性质将相对位姿变为世界系下的(local -> global)
- 减去求解出的增量零空间部分, 防止在零空间乱飘

- 将最新帧设置为参考帧, 并将所有的点向最新帧投影, 并且在金字塔从下向上使用协方差加权生成逆深度, 然后对于每一层使用周围点来尽可能生成像素逆深度, 这样保证有足够多得点来跟踪, 鲁棒。



- 边缘化使得点的残差变很少、最新一帧看不到、连续两帧外点, 主帧被边缘化的点候选边缘化或删除
- 如果是内点, 并且逆深度协方差小于阈值则标记为边缘化
- 其它的直接丢弃
- 把挑出来的边缘化点构造H- HSC /b- bSC, 加到HM, bM中

Residuals.cpp:

- 该文件主要求对各个状态**相对量**的Jacobian，因此对光度参数的Jacobian结果有变化，其它的对Target帧的结果相同。
- 在得到针对相对量的Jacobian之后，使用伴随性质将**相对的变为绝对的**，其中使用FEJ的部分，伴随也需要使用固定的线性化点位置来求。

滑窗中的光度参数求导

将 $\delta a = \frac{t_j e^{a_j}}{t_i e^{a_i}}$, $\delta b = b_j - \frac{t_j e^{a_j}}{t_i e^{a_i}} b_i$ 看成整体，分别对增量 a, b 求导：

$$\begin{aligned} \mathbf{J}_{\text{photo}} &= \frac{\partial r_k}{\partial \delta_{\text{photo}}} \\ &= \begin{pmatrix} \frac{\partial r_k}{\partial \delta a} & \frac{\partial r_k}{\partial \delta b} \end{pmatrix} \\ &= (- (I_i[\mathbf{p}] - b_i) \quad -1) \end{aligned} \tag{4'}$$

Residuals.cpp:

相机内参部分

设：

$$\omega(\mathbf{P}'_j) = \begin{bmatrix} \frac{P'_{jx}}{P'_{jz}} \\ \frac{P'_{jy}}{P'_{jz}} \\ 1 \end{bmatrix} = \begin{bmatrix} u_j \\ v_j \\ 1 \end{bmatrix} \quad (17)$$

根据公式 (3) 对相机内参求导，包括两部分 π_c , π_c^{-1} ，分别求偏导有

$$\frac{\partial \mathbf{P}_j}{\partial \delta \mathbf{c}} = \begin{pmatrix} u_j & 0 & 1 & 0 \\ 0 & v_j & 0 & 1 \end{pmatrix} + \begin{pmatrix} f_x & 0 \\ 0 & f_y \end{pmatrix} \begin{pmatrix} \frac{\partial u_j}{\partial \delta \mathbf{c}} \\ \frac{\partial v_j}{\partial \delta \mathbf{c}} \end{pmatrix} \quad (18)$$

滑窗中相机内参求导

对于第二部分

$$\begin{aligned} \frac{\partial \omega(\mathbf{P}'_j)}{\partial \mathbf{P}'_i} &= \frac{\partial \omega(\mathbf{P}'_j)}{\partial \mathbf{P}'_j} \frac{\partial \mathbf{P}'_j}{\partial \mathbf{P}'_i} \\ &= \frac{1}{P'_{jz}} \begin{pmatrix} 1 & 0 & -u_j \\ 0 & 1 & -v_j \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} r_{00} & r_{01} & r_{02} \\ r_{10} & r_{11} & r_{12} \\ r_{20} & r_{21} & r_{22} \end{pmatrix} \end{aligned} \quad (19)$$

$$\begin{aligned} \frac{\partial \mathbf{P}'_i}{\partial \delta \mathbf{c}} &= \frac{\partial \mathbf{K}^{-1} \mathbf{p}_i}{\partial \delta \mathbf{c}} \\ &= \begin{pmatrix} -f_x^{-2} (p_{ix} - c_x) & 0 & -f_x^{-1} & 0 \\ 0 & -f_y^{-2} (p_{iy} - c_y) & 0 & -f_y^{-1} \\ 0 & 0 & 0 & 0 \end{pmatrix} \\ &= \begin{pmatrix} -f_x^{-1} P'_{ix} & 0 & -f_x^{-1} & 0 \\ 0 & -f_y^{-1} P'_{iy} & 0 & -f_y^{-1} \\ 0 & 0 & 0 & 0 \end{pmatrix} \end{aligned} \quad (20)$$

Residuals.cpp:

结合公式 (17) (19) (20) 得到

$$\begin{aligned}\frac{\partial u_j}{\partial \delta \mathbf{c}} &= \frac{\partial u_j}{\partial \mathbf{P}'_i} \frac{\partial \mathbf{P}'_i}{\partial \delta \mathbf{c}} \\ &= \frac{1}{P'_z} (1 \quad 0 \quad -u_j) \mathbf{R} \begin{pmatrix} -f_x^{-1} P_x & 0 & -f_x^{-1} & 0 \\ 0 & -f_y^{-1} P_y & 0 & -f_y^{-1} \\ 0 & 0 & 0 & 0 \end{pmatrix} \\ &= \frac{1}{P'_z} \begin{pmatrix} P_x f_x^{-1} (r_{20} u_j - r_{00}) \\ P_y f_y^{-1} (r_{21} u_j - r_{01}) \\ f_x^{-1} (r_{20} u_j - r_{00}) \\ f_y^{-1} (r_{21} u_j - r_{01}) \end{pmatrix}^T\end{aligned}\quad (21)$$

$$\begin{aligned}\frac{\partial v_j}{\partial \delta \mathbf{c}} &= \frac{\partial v_j}{\partial \mathbf{P}'_i} \frac{\partial \mathbf{P}'_i}{\partial \delta \mathbf{c}} \\ &= \frac{1}{P'_z} \begin{pmatrix} P_x f_x^{-1} (r_{20} v_j - r_{10}) \\ P_y f_y^{-1} (r_{21} v_j - r_{11}) \\ f_x^{-1} (r_{20} v_j - r_{10}) \\ f_y^{-1} (r_{21} v_j - r_{11}) \end{pmatrix}^T\end{aligned}\quad (22)$$

结合公式 (18) (21) (22) 得到结果:

$$\begin{aligned}\frac{\partial \mathbf{p}_j}{\partial \delta \mathbf{c}} &= \begin{pmatrix} u_j & 0 & 1 & 0 \\ 0 & v_j & 0 & 1 \end{pmatrix} + \begin{pmatrix} f_x & 0 \\ 0 & f_y \end{pmatrix} \begin{pmatrix} \frac{\partial u_j}{\partial \delta \mathbf{c}} \\ \frac{\partial v_j}{\partial \delta \mathbf{c}} \end{pmatrix} \\ &= \begin{pmatrix} u_j & 0 & 1 & 0 \\ 0 & v_j & 0 & 1 \end{pmatrix} \\ &\quad + \frac{1}{P'_z} \begin{pmatrix} P_x (r_{20} u - r_{00}) & P_y \frac{f_x}{f_y} (r_{21} u - r_{01}) & (r_{20} u - r_{00}) & \frac{f_x}{f_y} (r_{21} u - r_{01}) \\ P_x \frac{f_y}{f_x} (r_{20} v - r_{10}) & P_y (r_{21} v - r_{11}) & \frac{f_y}{f_x} (r_{20} v - r_{10}) & (r_{21} v - r_{11}) \end{pmatrix}\end{aligned}\quad (23)$$

滑窗中相机内参求导

Residuals.cpp:

FrameFramePrecalc::set()

该函数设置关键帧间相对（host 到 target）的状态变量。

- 因为DSO部分状态使用FEJ，所以需要保存不同状态的值。
- 其中位姿 / 光度参数使用固定线性化点，逆深度 / 内参 / 图像导数都没有固定线性化点。
- 其中逆深度、内参、位姿这些几何参数使用中心点的值代替pattern内的。

FrameFramePrecalc::PRE_RTII_0 / PRE_tTII_0

该变量是固定的线性化点位置的状态增量。

FrameFramePrecalc::PRE_RTII / PRE_tTII

该变量是优化更新状态后的状态增量。

注：逆深度每次都会重新设置线性化点，相当于没有固定，虽然代码写的很像。

EnergyFunctional.cpp:

伴随

定义:

$$\text{Exp}(\text{Ad}_{\mathbf{T}} \cdot \xi) \doteq \mathbf{T} \text{Exp}(\xi) \mathbf{T}^{-1} \quad (24)$$

线性化点相对位姿和绝对位姿的关系:

$$\mathbf{T}_{th} = \mathbf{T}_{tw} \mathbf{T}_{hw}^{-1} \quad (25)$$

伴随得到**相对量对绝对量**导数

第一部分相对位姿se3对host se3导数:

对姿态进行左乘更新:

$$\text{Exp}(\delta \xi_{th}) \mathbf{T}_{th} = \mathbf{T}_{tw} (\text{Exp}(\delta \xi_h) \mathbf{T}_{hw})^{-1} \quad (26)$$

$$\begin{aligned} \text{Exp}(\delta \xi_{th}) &= \mathbf{T}_{tw} \mathbf{T}_{hw}^{-1} \text{Exp}(-\delta \xi_h) \mathbf{T}_{th}^{-1} \\ &= \mathbf{T}_{th} \text{Exp}(-\delta \xi_h) \mathbf{T}_{th}^{-1} \\ &= \text{Exp}(-\text{Ad}_{\mathbf{T}_{th}}(\delta \xi_h)) \end{aligned} \quad (27)$$

$$\delta \xi_{th} = -\text{Ad}_{\mathbf{T}_{th}} \delta \xi_h \quad (28)$$

所以:

$$\frac{\partial \xi_{th}}{\partial \xi_h} = -\text{Ad}_{\mathbf{T}_{th}} \quad (29)$$

EnergyFunctional.cpp:

第二部分相对位姿se3对target se3求导:

同样类似公式(21) - (24)的过程:

$$\text{Exp}(\delta \xi_{th}) \mathbf{T}_{th} = \text{Exp}(\delta \xi_t) \mathbf{T}_{tw} \mathbf{T}_{hw}^{-1} \quad (30)$$

$$\begin{aligned} \text{Exp}(\delta \xi_{th}) &= \text{Exp}(\delta \xi_t) \mathbf{T}_{tw} \mathbf{T}_{hw}^{-1} \mathbf{T}_{th}^{-1} \\ &= \text{Exp}(\delta \xi_t) \end{aligned} \quad (31)$$

$$\delta \xi_{th} = \delta \xi_t \quad (32)$$

最终有:

伴随得到**相对量对绝对量导数**

$$\frac{\partial \xi_{th}}{\partial \xi_t} = \mathbf{I} \quad (33)$$

第三部分相对光度参数对host和target求导

host和target之间的相对光度参数为

$$\delta a = -\frac{t_j e^{a_j}}{t_i e^{a_i}}, \quad \delta b = -b_j + \frac{t_j e^{a_j}}{t_i e^{a_i}} b_i \quad (34)$$

相对量对绝对量求导:

$$\begin{aligned} \frac{\partial \delta a}{\partial a_i} &= \frac{t_j e^{a_j}}{t_i e^{a_i}} = e^{\delta a} \\ \frac{\partial \delta b}{\partial b_i} &= \frac{t_j e^{a_j}}{t_i e^{a_i}} = e^{\delta a} \\ \frac{\partial \delta a}{\partial a_j} &= -\frac{t_j e^{a_j}}{t_i e^{a_i}} = -e^{\delta a} \\ \frac{\partial \delta b}{\partial b_j} &= \frac{t_j e^{a_j}}{t_i e^{a_i}} = -1 \end{aligned} \quad (35)$$

EnergyFunctional.cpp:

accumulateAF_MT()

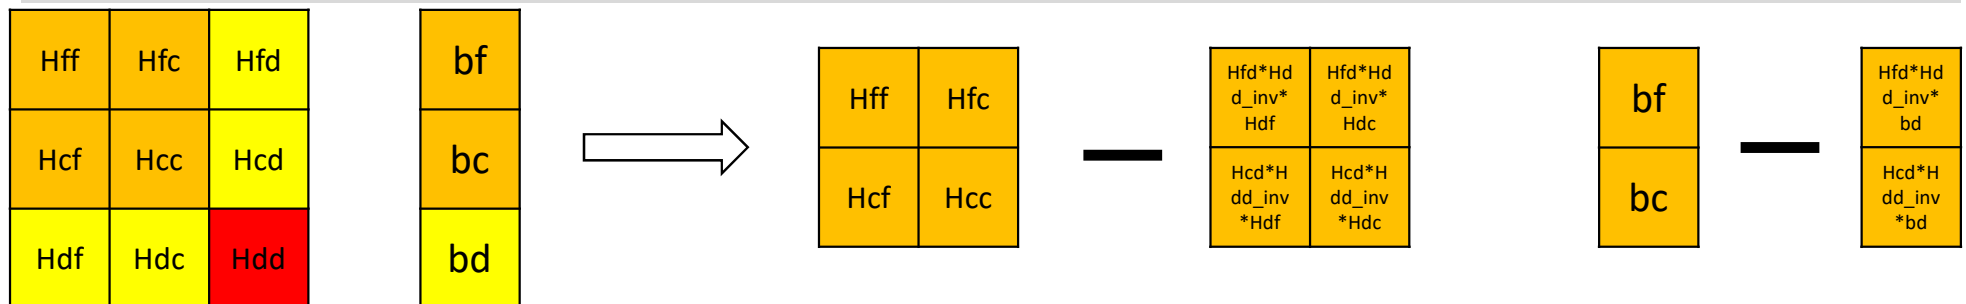
函数利用AccumulatedTopHessian.cpp中AccumulatedTopHessianSSE(mode=0)类对滑窗内的点计算正规方程，计算**H**和**b**，然后使用Adj转为绝对量。这里不包括逆深度相关量，因为被舒尔消元掉了。

accumulateLF_MT()

同样调用AccumulatedTopHessianSSE类只不过是mode=1，实际该函数中加入的点(isLinearized=true)是**不存在的**，因为被这样的点在边缘化时都删除了。**剩下的作用**包括：添加先验信息和把p->*LF相关的量置零。

accumulateSCF_MT()

调用AccumulatedSCHessian.cpp中AccumulatedSCHessianSSE类对滑窗内点**逆深度**相关的量进行计算，来完成**Schur消元**过程，同样使用Adj转为绝对量。



EnergyFunctional.cpp:

```
bM_top = (bM+ HM * getStitchedDeltaF())
```

这是对于被边缘化部分的残差像更新，HM和bM是边缘化得到的，后面详细说明。因为被边缘化后没办法project计算新的残差，因此使用一阶泰勒方式更新。注意，其中delta应该是绝对量。

```
EF->cPrior EF->cDeltaF
```

相机参数的先验信息：Hessian是很大的常数；delta估计值与设置的初值的差；

```
EF->frames->prior EF->frames->delta_prior
```

位姿光度的先验信息：第一帧位姿Hessian常数，光度Hessian常数(1e14)；其它帧位姿Hessian为零，光度Hessian常数(1e12/1e8)；delta估计值与固定线性化点的差

```
p->priorF; p->deltaF
```

点逆深度的先验信息：第一帧上的有(2500)，其它帧上的为0；delta值为0(因为线性化点被更新了)

FullSystemOptimize.cpp:

optimize()

- 在完成一次滑窗优化后，对于最新关键帧会设置当前的状态为FEJ状态，更新当前的待估计量，并且重新线性化一次，因为创建residual时是全部创建，这里删除不好的值。
- 对于其它的关键帧，将优化的状态更新到FrameShell，线性化点不变。
- 每次变动关键帧都会调用setPrecalcValues()，更新关键帧之间的相对状态。

EnergyFunctional::orthogonalize()

- 零空间**：求的方法是对状态进行数值求导，即 (正扰动-逆扰动) / (2*扰动)。我理解这部分就相当于观测方程 $y=cx$ 中的 c ，然后 $[c]$ 就是能观性方程，因此 c 应该是秩为0的，多出来的都是，因为零空间，从正规方程中减去零空间，即可抑制零空间漂移。

```
// 比最大奇异值小setting_solverModeDelta(e-5)倍，则认为是0
for(int i=0;i<SNN.size();i++)
{ if(SNN[i] > setting_solverModeDelta*maxSv) SNN[i] = 1.0 / SNN[i]; else SNN[i] = 0; } // 求逆

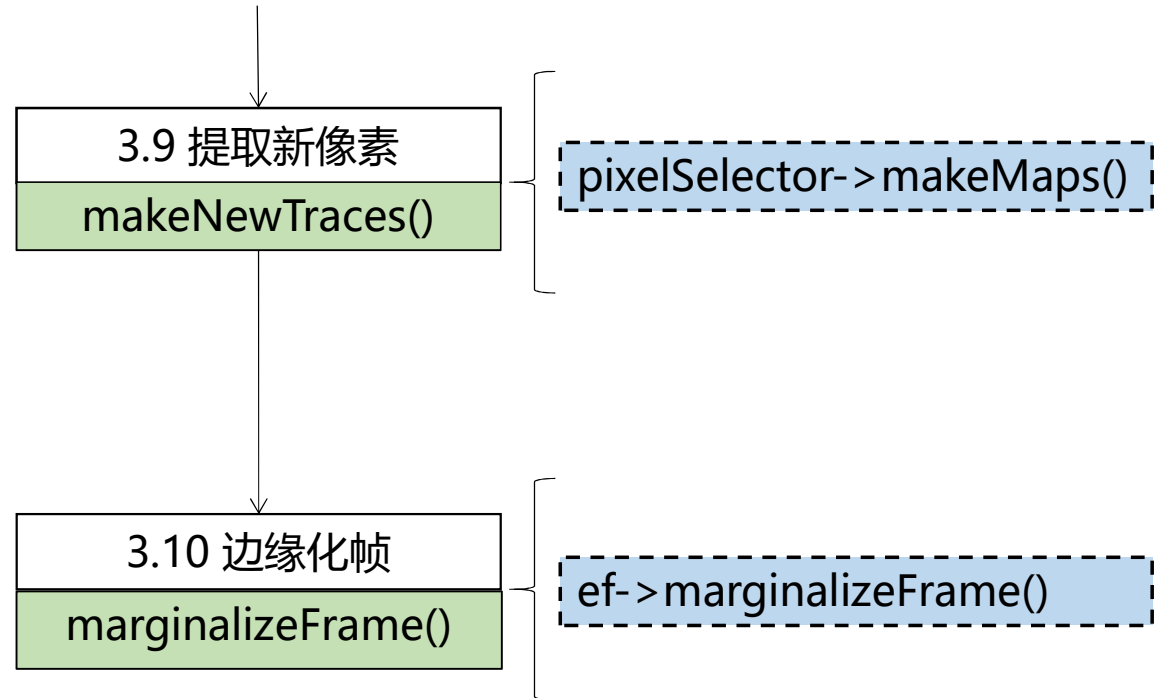
MatXX Npi = svdNN.matrixU() * SNN.asDiagonal() * svdNN.matrixV().transpose(); // [dim] x 7.
//! Npi.transpose()是N的伪逆
MatXX NNpiT = N*Npi.transpose(); // [dim] x [dim].
MatXX NNpiTS = 0.5*(NNpiT + NNpiT.transpose()); // = N * (N' * N)^-1 * N'.

//TODO 为什么这么做?
//* 把零空间从H和b中减去??? 以免乱飘?
if(b!=0) *b -= NNpiTS * *b;
if(H!=0) *H -= NNpiTS * *H * NNpiTS;
```

三、优化:

- 在最新帧第0层提取随机方向梯度最大的像素，并且构造成ImmaturePoint

- 将被边缘化的帧的8个状态挪到右下角，然后计算Schur Complement, 将其消掉
- 删除在被边缘化帧上的残差
- DSO里面操作的都是PoseGraph



EnergyFunctional.cpp:

marginalizePointsF()

函数调用AccumulatedTopHessianSSE(mode=2)和AccumulatedSCHessianSSE类分别针对被边缘化的点残差计算H/b和HSC/bSC, 然后舒尔消元后, 加权加在HM和bM上。

marginalizeFrame()

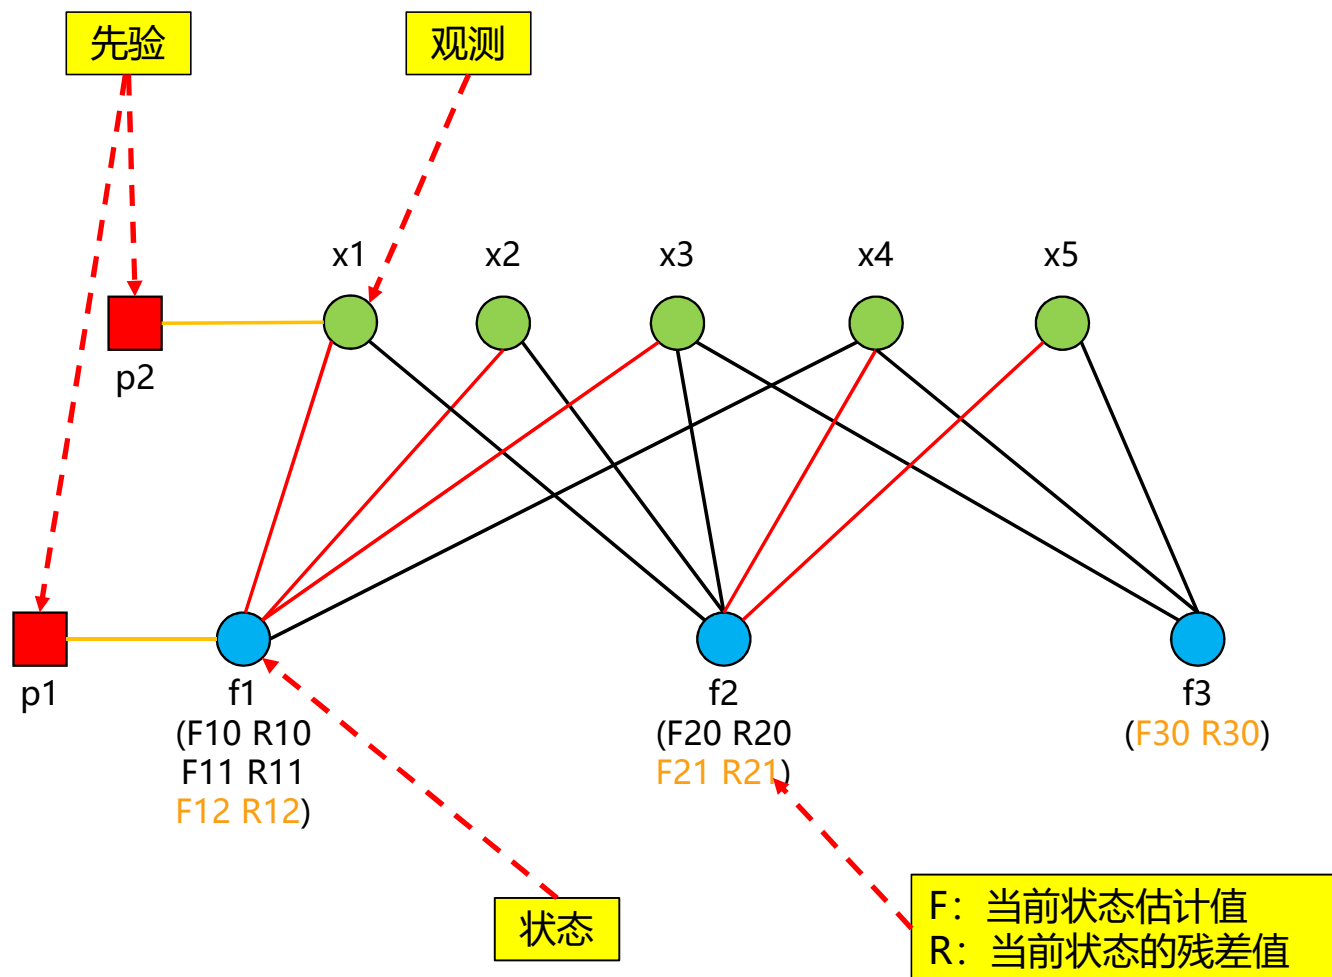
对于HM和bM进行边缘化 (消掉边缘化的帧) 操作。

fixLinearizationF()

因为状态需要固定在线性化点位置, 边缘化一个点前会重新线性化一次, 这时得到的resF是使用最新状态线性化的, 使用该函数减去 $J \times \text{delta}$ 得到在线性化点状态的residual。


边缘化例子:

f3为新加入的帧，
完成优化后得到状态
F12/R12,
F21/R21, F30/R30,
将F30/R30设置为
线性化点



边缘化例子：


使用Hessian来表示上述过程



边缘化例子:


x1、x2、x4边缘化掉，x3丢掉，构造边缘化先验HM，bM

边缘化:



边缘化例子：


边缘化之后会得到边缘化的先验矩阵，然后求解得状态：
F22/R22, F31/R31



边缘化例子:




使用Hessian来表示上述过程

边缘化后:




使用F20 F30计算

使用R21 R30计算



使用b-Hdx计算



解出F22/R22, F31/R31

Reference:

- [1] Engel J, Koltun V, Cremers D. Direct sparse odometry[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(3): 611-625.
- [2] <https://blog.csdn.net/xxxlinhttp/article/details/90640350>
- [3] <https://www.cnblogs.com/JingeTU/>
- [4] <https://zhuanlan.zhihu.com/p/29177540>
- [5] <https://zhuanlan.zhihu.com/p/74709586>
- [6] Xiang Gao. Notes on DSO. October 4, 2018

DSO注释:	https://github.com/alalagong/DSO
在线光度标定注释:	https://github.com/alalagong/online_photometric_calibration

谢谢聆听